1.實作ID3 decision tree 二元分類方法

第一題

3 feature = data['data']
4 target = data['target']

5 T=ID3DTtrain(feature[0:100,:],target[0:100])

```
In [1]:
         1 import math
          def entropy(p1,n1):
                if(p1==0 and n1==0):
                    return 1
          4
          5
                elif(p1==0 or n1==0):
          6
                   return 0
                else:
          8
                   pp=p1/(p1+n1)
                    np=n1/(p1+n1)
                    return -pp*math.log2(pp)-np*math.log2(np)
         11 # print(entropy(29,35))
In [2]:
         1 def IG(p1,n1,p2,n2):
                num1 = p1+n1
                num2 = p2+n2
                num=num1+num2
                return entropy(p1+p2,n1+n2)-num1/num*entropy(p1,n1)-num2/num*entropy(p2,n2)
          6 #print(IG(21,5,8,30))
          7 #print(IG(18,33,11,2))
         1 def ID3DTtrain(feature, target):
In [3]:
                node = dict()
                node['data']=range(len(target))
                                                      #data為編號
          4
                tree = []
          5
                tree.append(node)
                                                      #root=node
          6
                t=0
                                                      #編號+要生飾點嗎
                while(t<len(tree)):</pre>
          8
                    idx = tree[t]['data']
          9
                    if(sum(target[idx])==0):
                                                      #全部的target皆為0
         10
                        tree[t]['leaf']=1
                                                       #走到底了
                        tree[t]['decision']=0
                                                        #以後走到這就是@
                    elif(sum(target[idx])==len(idx)): #全部target都是1
                        tree[t]['leaf']=1
tree[t]['decision']=1
         13
                                                        #以後走到這都是1
         14
                                                      #沒切乾淨要再多切幾刀
         15
                    else:
         16
                        bestIG=0
                        for i in range(feature.shape[1]): #對每個feature都看-	op
         17
                            pool = list(set(feature[idx,i])) #看看編號idx的node裡的data 它們的feature i都長啥樣
         18
         19
                            pool.sort()
                            for j in range (len(pool)-1):
         20
                                thres = (pool[j]+pool[j+1])/2 #區分j和j+1的中間值 e.g. 1 7 9 > 4 6(共n-1)
         21
                                G1=[]
         23
                                G2=[]
         24
                                for k in idx:
         25
                                    if(feature[k][i]<thres): #如果小於thres分到group1
         26
                                        {\tt G1.append(k)}
                                                             #不是的話就分到 group2
         27
                                    else:
         28
                                       G2.append(k)
         29
                                p1=sum(target[G1]==1)
                                n1=sum(target[G1]==0)
         30
         31
                                p2=sum(target[G2]==1)
         32
                                n2=sum(target[G2]==0)
                                thisIG=IG(p1,n1,p2,n2)
         33
                                                     #把這個切法記起來
         34
                                if(thisIG>bestIG):
         35
                                    bestIG=thisIG
         36
                                    bestG1=G1
         37
         38
                                    bestthres=thres
                                                     #記起來最好的切分的feature是誰
         39
                                    bestf = i
                        if(bestIG>0): #如果切分更細有幫助的話
         40
                           tree[t]['leaf']=0
         41
                            tree[t]['selectf']=bestf
tree[t]['threshold']=bestthres
tree[t]['child']=[len(tree),len(tree)+1]
         42
         43
         44
         45
                            node=dict()
         46
                            node['data']=bestG1 #小於切分值得放右邊
         50
                            tree.append(node)
                                  #多切無益 姑且挑個比較好的值
         51
                           tree[t]['leaf']=1 #走到底了
         53
                            if(sum(target[idx]==1)>sum(target[idx]==0)): #因為1比0多
         54
                               tree[t]['decision']=1
                                                       #就讓他當1吧
         55
                            else:
         56
                                tree[t]['decision']=0
         57
                   t+=1
         58
                return tree
         59
         1 from sklearn import datasets
In [4]:
         2 data = datasets.load_iris()
```

2.完成單一樣本測試函式

第二題

3. IRIS 資料庫共有 150 筆資料,共有三類花各 50 筆,今僅取後 100 筆(即 target 為 1 及 2 兩 類)來實驗,請用這 100 筆資料 建樹,再用相同資料測試,試算其預測正確率。

Ans: 100%

4. 承上,若每類改用前 30 筆建樹,後 20 筆測試,試算其測試 資料的預測正確率。

Ans: 95%